

Destrier บน vLLM กับ SGLang

โมเดลเดียวกับที่ใช้อยู่ (Destrier + adapter ที่ซ่อมแล้ว) รวมเป็นไฟล์เดียวแล้วเสิร์ฟด้วยตัวเสิร์ฟที่เร็วกว่า Unsloth ทดสอบด้วยโค้ด worker ตัวจริง กับบ้านที่มีเฉลย 1 หลัง และบ้านจากเน็ตที่โมเดลไม่เคยเห็น 3 หลัง

วันที่ 3 ต.ค. 69 การ์ด RTX PRO 6000 96 GB เปิด 12:36–15:03 ค่าใช้จ่าย ~\$3.81 คั้นการ์ดแล้ว 0 instance

1. เปิดได้จริงไหม

เปิดได้ทั้งคู่

- ทางแก้ production พิสูจน์แล้ว
- ยังใช้แรงงานไม่ได้

ตอนแรกเปิดไม่ขึ้นเพราะชุด CUDA บนการ์ดไม่ตรงรุ่น แก้ใน presentation.py แล้ว ที่ยังใช้ไม่ได้เพราะโมเดลที่รวมแล้วยังไม่อยู่บน HuggingFace

2. เร็วขึ้นกี่เท่า

~57× vLLM

- SGLang ~44×

บ้าน 83b8e52c ทั้งหลังเหลือ 5 นาที จากเดิม 4 ชม. 43 นาที เทียบบนการ์ดเดียวกันต่อคำขอ pass0 เร็วขึ้น ~10 เท่า section ~20 เท่า

3. ผลอ่านเท่าเดิมไหม

ไม่แยกว่าเดิม

- อ่านผิมน้อยลงชัด
- ผลกว้างมาก

เจอมาร์คพอๆ เดิม แต่ precision ขึ้นจาก 0.63 เป็น 0.83–0.85 แยกไม่ได้ว่าดีขึ้นเพราะ adapter ที่ซ่อมหรือเพราะตัวเสิร์ฟ

ความเร็ว: บ้าน 83b8e52c ทั้งหลัง

29 หน้า ผ่าน worker ตัวจริงทุกชั้น (pass0 → ครอป → CV → gridline → pass2 → pass3)
ความยาวแบ่งตามเวลาจริงสเกลเดียวกัน

Unsloth + adapter
production เดิม

4 ชม. 43 นาที

vLLM
destrier-vllm

5.0 นาที · 57×

SGLang
destrier-sglang

6.4 นาที · 44×

16,964 วิ · 298.6 วิ · 382.1 วิ

ต่อคำขอ · การ์ดเดียวกัน	UNSLOTH	VLLM	SGLANG
pass0 จัดประเภทหน้า (ต่อหน้า)	18.5 วิ	1.6 วิ	2.7 วิ
section หน้า 22	170 วิ	~8 วิ	8.7 วิ
เขียนข้อความ	~20 ตัวอักษร/วิ	~440 ตัวอักษร/วิ	~460 ตัวอักษร/วิ
เปิดจนพร้อมรับงาน	80 วิ	170 วิ 576 วิ ถ้าเครื่องใหม่	65 วิ

ตัวเลข 57x รวมโซ่การ์ดด้วย รอบ production ได้การ์ดที่ pass0 ช้ากว่าการ์ดนี้ 4.7 เท่า ส่วน vLLM เร็วกว่า SGLang ทั้งหลังเพราะอ่านภาพเข้าเร็วกว่า ข้อดีที่เคยคาดไว้ของ SGLang (cache ส่วนต้นของ prompt) ใช้กับงานเราไม่ได้ เพราะ prompt ขึ้นต้นด้วยภาพซึ่งต่างกันทุกหน้า cache โดนแค่ 6 จาก 292 ครั้ง

ทำไมถึงเร็วขึ้น เล่าแบบเด็กอนุบาล

ข้อความสี่เทาตัวเล็กได้แต่ละข้อคือข้อจริงของเทคนิคนั้น

ลองนึกว่าโมเดลคือ แม่ครัว คนหนึ่ง เวลาตอบคำถาม แม่ครัวต้องวางคำตอบลงจานทีละคำ ทีละคำ เหมือนวางขนมทีละชั้น ยิ่งวางแต่ละชั้นเร็ว จานก็เสร็จเร็ว

ครัวเก่า · UNSLOTH

- แม่ครัวมีผู้ช่วยตั้ง 256 คน ทุกคำต้องเลือกผู้ช่วยมาช่วยไม่ก็คน แล้วเดินไปถามทีละคน
- สมุดสูตรทุกหน้ามีกระดาษโน้ตแปะไว้แก่สูตร ต้องหยิบโน้ตมาอ่านทุกครั้ง
- ทำเสร็จแต่ละชั้น ต้องหยุดรอหัวหน้าบอกว่าชั้นต่อไปทำอะไร

วางได้ราว 20 ตัวอักษรต่อวินาที

ครัวใหม่ · VLLM / SGLANG

- ลอกโน้ตลงสมุดสูตรเลย ไม่ต้องหยิบโน้ตมาอ่านอีก merge LoRA เข้าตัวโมเดล
- ผู้ช่วยที่เลือกมาทำงานพร้อมกันบนโต๊ะใหญ่ตัวเดียว ไม่ต้องเดินไปถามทีละคน fused MoE kernel
- แม่ครัวจำทำทั้งหมดได้แล้ว ทำต่อเนื่องได้เลย ไม่ต้องรอหัวหน้าสั่ง CUDA graph

วางได้ราว 440 ตัวอักษรต่อวินาที

แล้วทำไมถึง 57 เท่า วันที่บ้าน 83b8e52c ถูกถอดแบบครั้งแรก ครัวที่เข้ามาบังเอิญเป็นครัวช้า (การ์ดช้ากว่าวันนี้ 4.7 เท่า) ตัวเลข 57 เท่าจึงรวมโชคด้วย ถ้าเทียบในครัวเดียวกัน ครัวใหม่เร็วขึ้นราว 10–20 เท่า

บางงานไม่ได้เร็วขึ้น งานที่ไม่ได้ใช้แม่ครัว เช่น ตัดภาพ หรือหาเส้นด้วย CV ยังใช้เวลาเท่าเดิม ทั้งบ้านจึงเร็วขึ้นน้อยกว่าตัวแม่ครัว

รสชาติยังเหมือนเดิม แม่ครัวคนเดิม สูตรเดิม แคครัวทำงานเก่งขึ้น ด้านตรวจ C และ D ยืนยันว่าคำตอบที่ได้แทบเหมือนเดิม

ผลอ่านเทียบเฉลี่ย


บ้าน 83b8e52c หน้า 19–25 นับมาร์คที่อ่านเจอเทียบเฉลี่ย 52 มาร์ค ไม่ดูสเปกหรือขนาด

ชุด	JSON ผ่าน	มาร์คเจอ	มาร์คเกินมา	RECALL	PRECISION
production Unsloth + adapter เดิมที่ปนผิด	16/16	42/52	25	0.81	0.63
vLLM	16/16	41/52	7	0.79	0.85
SGLang	18/18	43/52	9	0.83	0.83

หน้า	ประเภท	PRODUCTION	VLLM	SGLANG	ที่ขาดบ่อย
19	แปลนฐานราก	4/10	8/10	8/10	C1 C2
20	แปลนคาน	11/15	11/15	13/15	CN ST1
21	แปลนหลังคา	2/2	0/2	1/2	B1 BX
22	รูปตัด	6/6	6/6	6/6	—
23	รูปตัด	3/3	3/3	3/3	—
24	แบบขยายคาน	12/12	9/12	10/12	B7 B7A
25	ตารางเสา	4/4	4/4	2/4	C1 C2

ยิงซ้ำ 3 รอบ ภาพเดิม เซิร์ฟเวอร์เดิม

แปลนคานหน้า 20 · จำนวนชั้น



- section หน้า 22: มาร์คตรง 6/6 · 4/6 · 4/6
- แปลนฐานรากหน้า 19: 8/10 ทุกกรอบ

ความต่างรายหน้าระหว่าง vLLM กับ SGLang ด้านบนจึงอยู่ในช่วงที่ sampling แกว่งเองอยู่แล้ว (temperature 0.7)

ด้านตรวจว่าโมเดลที่รวมไฟล์ยังเป็นตัวเดิม

A · expert ถูกแก้ ● 80/82

B · คำนำนักตรงสูตร ● ตรงเป๊ะ

C · ผลลัพธ์เทียบ ● 0.9956

Unsloth

D · vLLM ● top-1 สลับ

D · SGLang ● ผ่าน

D · vLLM แบบ ● ผ่าน

production

C ผ่านเพราะค่าคลาดพื้นฐานระหว่าง Unsloth กับ transformers เองคือ 0.9945 ส่วน D ของ vLLM สลับระหว่าง {" กับ `` ซึ่งไม่มีผลเมื่อบังคับ JSON

บ้านจากเน็ตที่โมเดลไม่เคยเห็น

แบบบ้านเพื่อประชาชน กรมโยธาธิการฯ ตรวจลายนิ้วมือภาพเทียบ 53 หลังในชุดเทรนแล้ว
ไม่ซ้ำ ไม่มีเฉลย จึงวัดเวลา JSON ที่ผ่าน และอาการชนเพดาน token

บ้าน	VLLM	VLLM อาการ	SGLANG	SGLANG อาการ	มาร์คตรงกัน
แบบประหยัด 1 1 ชั้น · 14 หน้า	218 วิ 21/22	● gridline วน	192 วิ 21/21	● ปกติ	0.45
แบบประหยัด 2 1 ชั้นยกใต้ถุน · 18 หน้า	530 วิ 31/32	● gridline วน	282 วิ 29/30	● gridline วน	0.55
ไทยเป็นสุข 4 2 ชั้น · 25 หน้า	557 วิ 40/41	● ชนเพดาน 3 ตัว	469 วิ 41/41	● ชนเพดาน 1 ตัว	0.57

ตัวเลขได้เวลาคือ JSON ที่ผ่านต่อคำขอทั้งหมด · มาร์คตรงกันคือสัดส่วนมาร์คที่ทั้งสองตัว
เสิร์ฟอ่านได้เหมือนกัน (Jaccard) · gridline วน = ไม่มี grid master ทั้งบ้าน ขึ้นวัดระยะ
(pass3) ถูกข้าม

ทำไมถึงวน: ต้นเหตุอยู่ที่ข้อมูลเทรน ไม่ใช่ตัวเสิร์ฟ

ท้ายคำตอบ gridline ของแบบประหยัด 1 ที่โดนตัดที่ 9,000 token (เขียนไป 18,473 ตัวอักษร) โมเดลไล่หน้าของบ้านเทรนหลังที่ 17 ไปถึงหน้า 317 ทั้งที่บ้านจริงมี 14 หน้า

```
... "image/บ้าน_เล็ก_1ชั้น_17/บ้าน_เล็ก_1ชั้น_17_หน้า315.png",  
  "image/บ้าน_เล็ก_1ชั้น_17/บ้าน_เล็ก_1ชั้น_17_หน้า316.png",  
  "image/บ้าน_เล็ก_1ชั้น_17/บ้าน_เล็ก_1ชั้น_17_หน้า317" ← โดนตัดตรงนี้
```

คำตอบที่ใช้สอน Destrier มี path ไฟล์ที่มีชื่อบ้านเทรนติดอยู่ และ prompt ก็สั่งให้เขียนไฟล์ source_image พอเจอบ้านที่ไม่รู้จัก โมเดลจึงแต่งชื่อบ้านเทรนขึ้นมาแล้ววน เกิดบนทั้งสองตัวเสิร์ฟแต่ไม่ทุกครั้ง

938/1034

คำตอบที่สอน มีชื่อบ้านเทรน

335/1034

มีบันทึกสคริปต์แก้ข้อมูลหลุดมา

183

ไฟล์ GT ที่มีบันทึกนี้ใน warnings

จดเป็นข้อ 68 ใน json_แก้ไขแล้ว/สิ่งที่ต้องแก้.md แก้ได้ที่ตัวสร้างชุดเทรนโดยไม่ต้องแตะไฟล์ GT

ที่เหลือให้ตัดสินใจ

เรียงตามที่เราคิดว่าคุ้มที่สุดก่อน

1	แก้ตัวสร้างชุดเทรนตามข้อ 68 (ตัด source_image และบันทึกสคริปต์ออก) แล้วเทรนใหม่ วัดซ้ำ ต้องเข้าการ์ดเทรนด้วยบ้านจากเน็ตชุดเดิม เกณฑ์คือ gridline ไม่ชนเพดาน
2	ทำ Stage 1 ของ adapter ที่ซ่อมแล้ว เพื่อแยกว่าที่อ่านผิดน้อยลงมาจาก adapter หรือจากตัวเสิร์ฟ ต้องเข้าการ์ด
3	รวมโมเดลใหม่แล้ว push ขึ้น dacarokann/destrier-merged ให้ GO.bat ข้อ 2/3 ต้องมี HF write token · ~45 นาที ใช้วันงานได้
4	ลอง temperature ต่ำลง ให้ผลอ่านนิ่งขึ้น (ตอนนี้แปลนคานหน้าเดียวกว้าง 22- แก้ worker บรรทัดเดียว ต้องวัดผล 56 ขึ้น)

รายงานเต็มและข้อมูลดิบ: Training · tune_ai/t05_Destrier/proof/04_vllm_sglang_บนการ์ด.md

commit: Constistant 9d4ba6b · Training 9fdb6d