

สรุปผลงาน AI ถอดแบบก่อสร้าง — t01 → t02 → t03 → t05 (Destrier)

รวบรวมจาก workmen's diary / workflow docs จริง · โมเดลฐาน Qwen3.6-35B-A3B (MoE) ทุกรอบ (ยกเว้น t04/t44 ที่ใช้ InternVL3-78B และตายไปแล้ว)

t01

21-24 ก.ค.

t02

28 ก.ค.

t03

24-25 ส.ค.

t05 Destrier

30-31 ส.ค.

Element recall (id ตรงกับเจเลย) — ยิ่งสูงยิ่งดี

t01

28.2%

t02

20.6%

t03

10.1%

t05

88.2%

mark_base

t05 ราย

43.5%

ตำแหน่ง

t01 สูงสุดแต่เทียบไม่แฟร์ — ภาพถูกย่อผิดปกติเหลือ ~266 token/ภาพ (บั๊ก) แทนที่จะเป็นพันกว่า token จริง ทำให้งานง่ายลงเทียม ๆ. t05 mark_base (88.2%) ให้อภัยการรวม/แยก element (เช่น "F4,C1" vs "F4"+"C1" แยกกัน) — เทียบใกล้เคียง t01-t03 ที่สุด. t05 รายตำแหน่ง (43.5%) วัดแค่ตำแหน่งถูกไหม ไม่สนชื่อ element เลย. (strict ตรงเป๊ะไม่ normalize อะไรเลย = 11.8%, ไม่แสดงในกราฟนี้เพราะเข้มนักว่าเกณฑ์ที่ t01-t03 ใช้)

JSON valid — โมเดลตอบเป็น JSON ที่ parse ได้ใหม่

90%

t01

65%

t02

97%

t03

—

t05

JSON ถูกฟอร์แมตไม่ได้แปลว่าอ่านแบบถูก — บทเรียนที่แพงที่สุดของโปรเจกต์ (t04 ได้ JSON valid ~96-100% แต่ recall 0%)

Over-predict — element ที่โมเดลโนเพิ่มขึ้นมาเอง (ยิ่งน้อยยิ่งดี)

t01

78 ตัว

t02

70 ตัว

วัดเฉพาะ t01/t02 (บน 20 ตัวอย่างเดียวกัน) — t03/t05 เปลี่ยนวิธีวัดเป็น per-subtask ไม่มีตัวเลขนี้บันทึกไว้ตรงๆ

สิ่งที่เปลี่ยนไปแต่ละรอบ

t01

ภาพย่อผิดพลาต (บั๊ก) — ผลดีเทียม

t02

ภาพความละเอียดจริง — คานทั้งหน้า recall 0%

t03

เพิ่ม pass0/2.4/3, กริดมาสเตอร์ฝังใน prompt

t05

รวม 4-fold soup, dataset 4 pass, ยังไม่รัน GPU จริง

ตายระหว่างทาง (คนละสถาปัตยกรรม — InternVL3, ไม่อยู่ในกราฟหลัก)

🐉 t04 Purson (InternVL3-78B)

ลืมเปิด crop_to_patches — รุลย่อเหลือ 256 token/รูป → recall 0% ทั้งที่ JSON สวย 96-100%

🐉 t44 Voldemort (InternVL3-78B 4-bit)

บีบอัด 4-bit ทำลาย ViT (ตา) — ดอบเห็น Barbie/BB-8 ในแบบก่อสร้าง จับได้ที่ประตู \$2 ก่อนเทรนเต็ม

สรุปจาก workmen's_diary + t01/t02/t03_workflow.md + t05_Destrier/proof · เกณฑ์วัดเดียวกันข้ามรอบ แต่ไม่ควบคุมตัวแปรเต็มที่ (คนละหน้า/prompt/decoding stack)