

แคตตาล็อก AI — ทางเลือกโมเดล Vision ขนาด 100-200B (นอกจาก Qwen)

รวบรวม 26 ส.ค. 2569 จากการค้นคว้าใน [2026-08-25.md](#) / [2026-08-25\(teach mk\).md](#) / [2026-08-26.md](#) เกณฑ์ที่ใช้: ขนาด 100-200B ($\pm$ กว้าง) · ไม่ใช่ Qwen ทั้งแบรนด์และ backbone · ใช้เชิงพาณิชย์ได้ · มีเครื่องมือเทรน LoRA ที่ยืนยันว่าใช้ได้จริง (ไม่ใช่แค่เอกสารอ้าง)

เราใช้อยู่ปัจจุบัน: [Qwen3.6-35B-A3B](#) (35B, Apache-2.0, เทรนอยู่แล้วในโปรเจกต์นี้)

ตารางสรุปทั้งหมด

โมเดล	ขนาด	ไลเซนส์	เชิงพาณิชย์	เทรน LoRA ได้จริงไหม	ดกรอบเพราะ
InternVL3-78B	78B	Apache (สืบจาก Qwen2.5-72B)	✓	✓ LLaMA-Factory/ms-swift (✗ Unsloth ใช้ไม่ได้)	ข้างในใช้ Qwen2.5-72B เป็นสมอง — แบรินต์อื่นแต่นับเป็น Qwen
InternVL3.5-241B-A28B	241B	Apache (สืบจาก Qwen3-235B)	✓	ไม่ยืนยัน	ข้างในใช้ Qwen3-235B เป็นสมอง เหตุผลเดียวกับด้านบน
GLM-4.6V	~100B+	MIT	✓	✗ มีบั๊กเปิดอยู่ (LLaMA-Factory#9635, NotImplementedError)	เทรน LoRA ไม่ได้เพราะบั๊ก ยังไม่มีคนแก้
Llama-3.2-90B-Vision	90B	Meta (ฟรีถ้า MAU<700M)	✓	ไม่ยืนยันเทียบเท่า Scout	ยังไม่ทดสอบภาษาไทย
Llama-4-Scout	~100B+	Meta (ฟรีถ้า MAU<700M)	✓	✓ Unsloth (4-bit เท่านั้น) หรือ LLaMA-Factory (มีคนรันจริงบน 8×H100)	รอดครบทุกเงื่อนไข — แต่ยังไม่เคยทดสอบอ่านภาษาไทย
Pixtral-Large	~124B	Mistral Research License	✗	ไม่มี framework หลักยืนยัน	ห้ามใช้เชิงพาณิชย์ตรงๆ ต้องซื้อไลเซนส์แยก
Molmo-72B	72B (bf16 จริง ~147GB)	—	ไม่ยืนยัน	✗ ไม่มี framework หลักยืนยัน	ไม่มีเครื่องมือเทรนที่ยืนยันว่าใช้ได้
NVLM-D-72B	72B	CC-BY-NC-4.0	✗	✗ (vLLM เองก็ยังไม่รันไม่ได้ — NVIDIA ยอมรับเอง)	ห้ามใช้เชิงพาณิชย์เต็มๆ + รันไม่ได้ด้วยซ้ำ
ERNIE-4.5-VL-28B-A3B	28B	—	✓ (Unsloth มี notebook จริง)	✓ Unsloth	เล็กเกินไป ไม่เข้าเกณฑ์ขนาด (28B < 72B)

โมเดล	ขนาด	ไลเซนส์	เชิงพาณิชย์	เทรน LoRA ได้จริงไหม	ดกรอบเพราะ
Nemotron 3 Nano Omni	30B (active 3B)	NVIDIA Nemotron Open Model License	✅	ไม่ยืนยัน	เลิกเกินไป — แต่ license สะอาดสุดในลิสต์นี้
GLM-5V-Turbo	ไม่เปิดเผย	ปิด (API เท่านั้น)	—	❌ ดาวนโหลดมาเทรนเองไม่ได้	ไม่ open-weight เลย
MiniMax M3	428B รวม / 22B active	เงื่อนไขซับซ้อน (ฟรีถ้าไม่ใช่เชิงพาณิชย์)	⚠️ ต้องอ่าน terms	มี NeMo AutoModel รองรับ	ไลเซนส์ก้าวม fine-tune ไปใช้จริงอาจนับเป็น commercial

ผลชี้ขาด

ตัวเดียวที่รอดครบทุกเงื่อนไข (ขนาด + license + เทรนได้จริง): **Llama-4-Scout** รองลงมา GLM-4.6V (license ผ่าน แต่ติดบ๊ักเทรนไม่ได้ตอนนี้)

ยังไม่มีใครทดสอบว่าตัวไหนอ่านภาษาไทยได้ดีแค่ไหน — แนะนำ zero-shot Thai-OCR test ก่อนตัดสินใจลงทุนเช่า GPU จริงกับตัวไหนก็ตาม

ทำไมถึงหายาก: โมเดล vision ระดับ 100-200B ที่เปิดจริง (Apache/MIT) ส่วนใหญ่ในตลาดตอนนี้ **ยืมสมองจาก Qwen มาใช้** (InternVL ทั้งหมด) — ตัวที่ไม่ใช่ Qwen เลยสักส่วน มักมาพร้อมไลเซนส์ ที่มีเงื่อนไขซับซ้อน (Pixtral, NVLM, MiniMax) ยกเว้น Llama ตระกูล Meta ที่เปิดกว้างที่สุด

แคตตาล็อกนี้เป็นภาพรวม — รายละเอียดการค้นคว้าที่ละขั้นตอนอยู่ที่ *diary* วันที่เกี่ยวข้องด้านบน